

BLM308 Veri Madenciliği — Final Proje Raporu

Akıllı Sulama Sistemi: Sensör Verileri ile Otonom Karar Modeli

Serra Tengis — 231041034
İstanbul Gedik Üniversitesi, Bilgisayar Mühendisliği

Bahar 2026

Takım Bilgileri ve Rol Dağılımı

Ad Soyad	Numara	Rol	Yaptığı Bölümler
Serra Tengis	[231041034]	Veri & Model Müh.	Veri ön işleme, kodlama, istatistiksel analiz, hiperparametre optimizasyonu ve LaTeX raporlama (Bireysel)

Proje türü: Uçtan uca pipeline ve IoT Dağıtım (Deployment) Senaryosu

Takım büyüklüğüne göre ek kapsam: Bireysel proje (1 veri seti + 3 sınıflandırıcı + temel ön işleme + LaTeX Rapor + GitHub)

Özet

Bu çalışmada, tarımsal ve evsel sulama sistemlerinde su israfını önlemek, enerji verimliliğini sağlamak ve bitki sağlığını korumak amacıyla çevresel sensör verilerine dayalı akıllı bir karar destek sistemi geliştirilmiştir. Küresel tatlı su tüketiminin büyük bir bölümünün tarımda kullanıldığı günümüzde, toprağın anlık nemine dayalı sabit eşik değerli geleneksel sistemler yetersiz kalmaktadır. Bu bağlamda, Kaggle platformu üzerinden elde edilen 16.411 satırlık kapsamlı tarım veri seti (Smart Agriculture Dataset) kullanılarak çok sınıflı (0: Sulama Yapma, 1: Normal Sula, 2: Yoğun Sula) bir makine öğrenmesi modeli eğitilmiştir. Çalışma kapsamında J48 (Karar Ağacı), Random Forest ve IBk (K-En Yakın Komşu) algoritmaları 10-fold cross-validation yöntemi ile detaylı olarak karşılaştırılmıştır. Deneyler sonucunda en yüksek doğrulama başarısı J48 (0.9026) algoritması ile elde edilmiştir. Sonuçlar, doğrusal olmayan çevresel ilişkilerin karar ağaçları ile başarıyla modellenebildiğini ve bu yapının ESP32 tabanlı bulut destekli (Firebase/MQTT) IoT sistemlerine otonom bir "beyin" olarak entegre edilebileceğini bilimsel olarak kanıtlamaktadır.

Anahtar kelimeler: veri madenciliği, sınıflandırma, akıllı tarım, IoT, Random Forest, J48, ESP32, CRISP-DM.

İçindekiler

1 Giriş	3
1.1 Problem Tanımı	3
1.2 Motivasyon ve İş Değeri	3
1.3 Literatür ve İlgili Çalışmalar	3
1.4 Raporun Yapısı	3
1.5 Araştırma Hedefleri ve Özgün Değer	4
1.6 Yaygın Etki ve Gelecek Vizyonu	4
2 Proje Yönetimi ve İş Kırılımı	4
2.1 Çevik (Agile) Geliştirme Süreci	4
2.2 Zaman Çizelgesi ve Görev Dağılımı	4
3 Yöntem (CRISP-DM)	5
3.1 Genel Akış	5
3.2 Kullanılan Araçlar	5
4 Veri Anlayışı ve Hazırlığı	6
4.1 Veri Kaynağı	6
4.2 Veri Tanımı	6
4.3 Keşifsel Veri Analizi (EDA)	6
4.4 Veri Ön İşleme (Data Preprocessing)	7
5 Modelleme ve Algoritmalar	7
5.1 Algoritmaların Teorik Altyapısı	7
5.2 Deney Kurulumu ve Hiperparametre Optimizasyonu	8
6 Değerlendirme ve Sonuçlar	8
6.1 Performans Metrikleri	8
6.2 Hata Analizi ve Confusion Matrix	8
6.3 Bias-Variance (Yanlılık ve Varyans) Yorumu	9
7 Dağıtım (Deployment) ve Gelecek Çalışmalar	9

1 Giriş

1.1 Problem Tanımı

Artan dünya nüfusu ve küresel iklim değişikliği, tatlı su kaynakları üzerindeki baskıyı her geçen gün artırmaktadır. Bu durum, suyun sürdürülebilir yönetimini kritik bir gereklilik haline getirmiştir[cite: 454]. Geleneksel otomatik sulama sistemleri, genellikle topraktaki nem oranını baz alan tek parametrelili basit kurallarla (örneğin: "nem %30'un altına düştüğünde su pompasını aç") çalışmaktadır. Ancak bitkilerin fizyolojik su ihtiyacı sadece toprağın nemiyle değil; hava sıcaklığı, havadaki bağıl nem ve bitkinin gelişim evresi gibi çok sayıda dış faktörle doğrudan ilişkilidir. Yalnızca toprağa odaklanan statik sistemler, sıcak ve kurak günlerde yetersiz kalırken, nemli veya yağışlı günlerde aşırı sulamaya yol açarak kök çürümmesine, mantar hastalıklarına ve ciddi su israfına neden olmaktadır. Çözülmesi gereken temel problem, çok değişkenli bu çevresel verileri anlamlandırarak anlık ve doğru sulama kademesini (hiç sulamama, normal sulama, yoğun sulama) belirleyebilecek, insan müdahalesine gerek duymayan otonom bir tahmin modeli geliştirmektir.

1.2 Motivasyon ve İş Değeri

Bu problemin veri bilimi ve makine öğrenmesi algoritmaları kullanılarak çözülmesi; tarım işletmeleri, endüstriyel seralar ve evsel akıllı bahçe sistemleri kullanıcıları için muazzam bir iş değeri taşır. Sistemin duruma göre proaktif kararlar alması, su kaynaklarının ve sulama için harcanan elektrik enerjisinin optimizasyonunu sağlar. Ayrıca bu veri modeli, karar verici bir API (Uygulama Programlama Arayüzü) olarak hizmet vererek sensör donanımlarının otonom çalışmasını sağlar. Bu sayede tarımsal faaliyetlerdeki operasyonel maliyetler düşürülür, verim kaybı önlenir ve çevresel sürdürülebilirliğe doğrudan katkı sağlanır.

1.3 Literatür ve İlgili Çalışmalar

Sistemin kavramsal çerçevesini oluşturmak ve literatürdeki eksiklikleri tespit etmek amacıyla ilgili çalışmalar detaylıca incelenmiştir[cite: 442, 443]. Taştan (2019), ESP8266 tabanlı NodeMCU ve toprak nem sensörü verilerinin Blynk platformu üzerinden izlendiği bir mimari sunmuştur[cite: 444]. Benzer şekilde, Arduino Uno ve ESP8266 kullanılarak ThingSpeak üzerinden yönetilen sistemler tasarlanmıştır[cite: 445]. Yenikaya ve ark. (2022) ise donanım mimarisine pH ve EC gibi ek sensörler entegre ederek Cayenne platformu üzerinden izleme sağlamıştır[cite: 446].

Haberleşme ve kontrol noktasında, Alpay (2021) GSM şebekesi üzerinden DTMF sesli arama tonları ile kontrol edilen birimler önermiş[cite: 447]; Öztürk ve ark. (2021) ise Bluetooth modülleri ile Android entegrasyonu sağlamıştır[cite: 448]. Otonom karar destek mekanizmaları alanında, güneş enerjisi destekli sistemler ve FAO Penman-Monteith yöntemiyle su tüketimini analiz eden yaklaşımlar da mevcuttur[cite: 450]. Ancak mevcut çalışmaların büyük bir bölümü sabit bir nem eşik değerine dayalı genel sulama yapmakta veya kural tabanlı basit kodlamalar kullanmaktadır[cite: 438]. Bu proje, makine öğrenmesi algoritmalarını (özellikle J48 Karar Ağacı) merkeze alarak, ortam değişkenlerini bütüncül değerlendiren çok sınıflı ve dinamik bir karar katmanı oluşturması yönüyle literatürdeki eksikliği doldurmayı hedeflemektedir.

1.4 Raporun Yapısı

Bu rapor, Veri Madenciliği projeleri için endüstri standardı olan CRISP-DM metodolojisine uygun olarak yapılandırılmıştır. Bölüm 2'de CRISP-DM akışı ve kullanılan araçlar tanıtılmış, Bölüm 3'te verinin kaynağı, keşifsel veri analizi ve ön işleme adımları açıklanmıştır. Bölüm 4'te seçilen makine öğrenmesi algoritmalarının teorik altyapısı ve hiperparametre ayarları verilmiş, Bölüm 5'te modelin başarımları metriklerle analiz edilmiştir. Son olarak Bölüm 6'da IoT donanım entegrasyonuna (Dağıtım) dair gelecek vizyonu tartışılmıştır.

1.5 Araştırma Hedefleri ve Özgün Değer

Bu projenin temel araştırma hedefi, geleneksel eşik tabanlı tarımsal sulama sistemlerinin yerini alabilecek, çevreye duyarlı ve otonom bir yapay zeka entegrasyonu sunmaktır. Literatürdeki mevcut sistemlerin birçoğu ya kapalı devre donanımlara hapsolmuş ya da yalnızca toprak nemi gibi tekil bir değişkene indirgenmiştir. Bu çalışmanın özgün değeri, havadaki bağıl nem ve sıcaklık gibi çoklu çevresel faktörleri eş zamanlı olarak değerlendirerek, makine öğrenmesi algoritmaları (özellikle Karar Ağaçları) ile anlık bir "sulama kademesi" (0, 1, 2) belirleyen dinamik bir süreç kurgulamasıdır. Böylece sabit kurallara bağlı kalmayan, bitkinin ve ortamın anlık ihtiyacına göre şekillenen esnek bir yapı elde edilmiştir.

1.6 Yaygın Etki ve Gelecek Vizyonu

Geliştirilen bu modelin fiziksel bir IoT mimarisine (ESP32 ve röle modülleri) entegre edilmesiyle elde edilecek yaygın etki çok boyutludur. Çevresel boyutta, gereksiz sulamanın önüne geçilerek tatlı su kaynaklarının korunması sağlanacaktır. Ekonomik boyutta ise, su motorlarının yalnızca optimum zamanlarda ve ihtiyaç duyulan süre kadar çalıştırılmasıyla tarım işletmelerinin enerji ve donanım bakım maliyetleri minimize edilecektir. Projenin genişletilebilir mimarisi, gelecekte sadece sulama değil; akıllı sera havalandırması veya otonom gübreleme sistemleri gibi farklı tarımsal süreç diyagramlarına (Process Diagrams) da kolayca entegre edilebilir bir altyapı sunmaktadır.

2 Proje Yönetimi ve İş Kırılımı

2.1 Çevik (Agile) Geliştirme Süreci

Bu veri madenciliği projesinin araştırma, veri ön işleme ve modelleme adımları, yazılım mühendisliği disiplinlerine uygun olarak Çevik (Agile) proje yönetimi prensipleriyle yürütülmüştür. Geliştirme süreci, her biri belirli bir probleme ve teslimat odaklanan ardışık döngülere (Sprint) bölünmüştür. Bu metodolojik yaklaşım, verideki eksikliklerin erken aşamada tespit edilmesini ve makine öğrenmesi algoritmalarının iteratif olarak iyileştirilmesini sağlamıştır.

2.2 Zaman Çizelgesi ve Görev Dağılımı

Bireysel bir araştırma projesi olmasına rağmen, veri bilimi ve donanım entegrasyonu vizyonunun sağlıklı bir şekilde dokümanate edilebilmesi için proje iş kırılım yapısı (WBS) aşağıdaki gibi planlanmıştır:

Aşama	Yapılan İşlemler (Backlog)	Çıktılar ve Hedefler
Sprint 1 (Veri Anlayışı)	Kaggle veri setinin temin edilmesi, sensör dağılım grafiklerinin (EDA) çizilmesi ve veri karakteristiğinin incelenmesi.	Veri seti anatomisi, bağımlı ve bağımsız değişken tespitleri.
Sprint 2 (Ön İşleme)	Eksik (NaN) değerlerin ortalama (mean) ile doldurulması, Label Encoding ve Standardizasyon işlemlerinin kodlanması.	Makine öğrenmesine hazır, temizlenmiş veri seti matrisi.
Sprint 3 (Modelleme)	J48, Random Forest ve IBk algoritmalarının 10-Fold Cross Validation ile eğitilmesi ve hiperparametre ayarları.	Eğitilmiş modeller ve performans karşılaştırma metrikleri.
Sprint 4 (Raporlama)	Confusion Matrix analizi, Bias-Variance yorumlamaları ve IoT (ESP32) donanım entegrasyon senaryosunun LaTeX ile dokümantasyonu.	Eksiksiz proje raporu ve otonom sistem mimarisi dokümanı.

Tablo 1: Proje Geliştirme Süreci ve Sprint Akışı

3 Yöntem (CRISP-DM)

3.1 Genel Akış

Proje, "Cross-Industry Standard Process for Data Mining" (CRISP-DM) standartlarına tam uyumlu olarak 6 aşamada gerçekleştirilmiştir:

- İş Anlayışı (Business Understanding):** Tarımsal su israfı probleminin tanımlanması ve akıllı karar destek mekanizması hedeflerinin belirlenmesi.
- Veri Anlayışı (Data Understanding):** Kaggle veri setinin toplanması, özelliklerin (sıcaklık, nem, toprak yapısı) incelenmesi ve Keşifsel Veri Analizi (EDA) grafiklerinin oluşturulması.
- Veri Hazırlığı (Data Preparation):** Eksik verilerin (NaN) tedavi edilmesi, kategorik değişkenlerin sayısallaştırılması ve verilerin standartlaştırılması.
- Modelleme (Modeling):** Scikit-learn kütüphanesi kullanılarak J48, Random Forest ve KNN algoritmalarının eğitilmesi.
- Değerlendirme (Evaluation):** Modellerin 10-fold cross-validation ile çapraz doğrulama-dan geçirilmesi, Confusion Matrix ve F1-Score gibi metriklerle hata analizi yapılması.
- Dağıtım (Deployment):** Geliştirilen modelin ESP32 ve MQTT protokolü kullanılarak gerçek dünya donanımlarına entegre edilme senaryosunun tasarlanması.

3.2 Kullanılan Araçlar

- Geliştirme Ortamı:** Python 3.x (Google Colab bulut ortamı)
- Veri Manipülasyonu:** pandas, numpy
- Makine Öğrenmesi:** scikit-learn (Model inşası, metrik hesaplama, cross-validation)
- Görselleştirme:** matplotlib.pyplot, seaborn

4 Veri Anlayışı ve Hazırlığı

4.1 Veri Kaynağı

Araştırmada kullanılan veri seti, akıllı tarım optimizasyonu araştırmaları için sıklıkla referans alınan ve Kaggle platformunda açık kaynaklı olarak paylaşılan "Smart Agriculture Dataset" arşivinden (`cropdata_updated.csv`) elde edilmiştir.


4.2 Veri Tanımı

Kriter	Açıklama
Örnek Sayısı (Satır)	16.411 benzersiz okuma kaydı
Öznitelik Sayısı (Sütun)	6 adet özellik sütunu
Bağımsız Değişkenler	<code>soil_type</code> (Toprak Tipi), <code>Seedling Stage</code> (Büyüme Evresi), <code>MOI</code> (Toprak Nemi), <code>temp</code> (Hava Sıcaklığı), <code>humidity</code> (Bağıl Hava Nemi)
Hedef Değişken	<code>result</code> (Otonom sulama kararı)
Sınıf Sayısı ve Dağılımı	3 Sınıf (Multi-class Classification): 0 (Sulama Yapma), 1 (Normal Sula), 2 (Yoğun Sula)

Tablo 2: Veri Seti Özellikleri ve Yapısı

4.3 Keşifsel Veri Analizi (EDA)

Modeli eğitmeden önce veri setinin içsel yapısını anlamak amacıyla EDA (Exploratory Data Analysis) süreci yürütülmüştür. Her bir bağımsız değişkenin hedef değişken (`result`) üzerindeki dağılımları histogramlar aracılığıyla incelenmiştir. Gözlemler sonucunda; sıcaklık (`temp`) değişkeninin 30°C'yi aştığı durumlarda veri setindeki Sınıf 2 (Yoğun Sula) etiketlerinin logaritmik olarak arttığı tespit edilmiştir. Hava nemi (`humidity`) ve toprak nemi (`MOI`) arasında güçlü bir negatif korelasyon gözlemlenmiş olup, bu durum karar ağaçlarının dallanma (splitting) süreçlerinde yüksek bir Bilgi Kazancı (Information Gain) sağlayacağını habercisidir.



Şekil 1: Sensör Verilerinin Keşifsel Dağılım Analizi (EDA)

4.4 Veri Ön İşleme (Data Preprocessing)

Makine öğrenmesi algoritmalarının matematiksel fonksiyonları yalnızca sayısal verileri işleyebildiği için aşağıdaki dönüşüm ve temizleme işlemleri kodlanmıştır:

1. **Kodlama (Label Encoding):** `soil_type` (Örn: Killi, Kumlu) gibi metinsel sınıflar `scikit-learn` içerisindeki `LabelEncoder` kütüphanesi kullanılarak 0, 1, 2 şeklinde tamsayılara dönüştürülmüştür.
2. **Eksik Değerlerin İmpütasyonu:** Gerçek dünyadaki sensör hatalarından kaynaklanabilecek eksik hücreler (NaN), veri kaybını engellemek amacıyla o sütunun aritmetik ortalaması (mean) hesaplanarak doldurulmuştur (`df.fillna`).
3. **Standardizasyon (Z-Score Normalization):** Sıcaklık (20-40) ve nem (0-100) verilerinin ölçekleri birbirinden farklıdır. Ölçek farkının KNN gibi mesafe tabanlı algoritmaları manipüle etmesini önlemek amacıyla `StandardScaler` uygulanmıştır. Formülizasyon şu şekildedir:

$$z = \frac{x - \mu}{\sigma}$$

Burada x örnek değeri, μ ortalamayı, σ ise standart sapmayı ifade etmektedir.

5 Modelleme ve Algoritmalar

5.1 Algoritmaların Teorik Altyapısı

Projede performans kıyaslaması yapmak adına üç farklı makine öğrenmesi ekolü tercih edilmiştir:

- **J48 (Decision Tree - Karar Ağacı):** Veri setini en yüksek Bilgi Kazancını (Information Gain) sağlayacak şekilde özyinelemeli olarak bölen bir algoritmadır. Çevresel sensörlerin "Eğer sıcaklık > 30 ise..." gibi doğrusal olmayan eşik değerlerini yakalamada çok başarılıdır. Şeffaf ve yorumlanabilir (Explainable AI) bir model sunar.

- **Random Forest (Rassal Orman):** Ensemble (topluluk) öğrenme mantığıyla çalışır. Eğitim verisinden Bootstrap yöntemiyle alt kümeler oluşturur ve çok sayıda bağımsız karar ağacı inşa eder. Nihai karar, bu ağaçların çoğunluk oyu (Majority Voting) ile belirlenir. Genellikle varyansı (variance) düşürerek yüksek tahmin başarısı sunar.
- **IBk (K-Nearest Neighbors):** Öğrenme işlemini eğitim aşamasında yapmayan, tembel (lazy) bir algoritmadır. Yeni bir sensör verisi geldiğinde, eğitim setindeki en yakın k adet komşusunun Öklid mesafesine bakarak sınıf ataması yapar. Formülü şöyledir:

$$d(p, q) = \sqrt{\sum_{i=1}^n (q_i - p_i)^2}$$

5.2 Deney Kurulumu ve Hiperparametre Optimizasyonu

Modellerin eğitim ve test performansı, istatistiksel geçerliliğini kanıtlamak amacıyla **10-fold cross-validation** (10 katlı çapraz doğrulama) kullanılarak ölçülmüştür. Modellerin hiperparametreleri aşağıdaki tabloda görüldüğü gibi ayarlanmıştır.

Model	Optimizasyon Parametresi	Seçilen Değer / Gerekçe
Decision Tree (J48)	<code>criterion</code>	gini (Hesaplama maliyeti düşük)
Decision Tree (J48)	<code>random_state</code>	42 (Deneylerin tekrarlanabilirliği için)
Random Forest	<code>n_estimators</code>	100 (Aşırı öğrenmeyi (overfitting) dengelemek için)
K-Nearest Neighbors	<code>n_neighbors</code> (k)	5 (Gürültüye duyarlılığı azaltmak için)

Tablo 3: Uygulanan Hiperparametre Ayarları

6 Değerlendirme ve Sonuçlar

6.1 Performans Metrikleri

Modellerin kıyaslanmasında Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık (Recall) ve F1-Skoru dikkate alınmıştır. Doğruluk metriği tek başına yeterli değildir; özellikle yanlış sülama kararlarının bitki ölümüne yol açabileceği bu senaryoda Recall (Gerçek pozitifleri yakalama oranı) çok daha kritiktir.


Model	Accuracy (10-Fold CV)	Precision (Test)	Recall (Test)	F1-Score (Test)
J48 (Karar Ağacı)	0.9026	-	-	-
Random Forest	0.8477	0.99	0.99	0.99
IBk (KNN)	0.6877	-	-	-

Tablo 4: Sınıflandırıcıların Performans Sonuçları

6.2 Hata Analizi ve Confusion Matrix

En başarılı modellerden olan Random Forest'ın test verisi üzerindeki karmaşıklık matrisi (Confusion Matrix) aşağıda sunulmuştur. Matris incelendiğinde, projenin temel amacı olan "bitkiyi susuz bırakmama" senaryosunun başarıyla çalıştığı görülmektedir. Gerçekte "Yoğun Sula (Sınıf 2)" olması gereken kritik anlarda modelin hatalı şekilde "Sulama Yapma (Sınıf 0)" kararı vermesi (False Negative) çok düşük oranlardadır. İş değeri perspektifinden; bir sisteme fazladan az

miktarda su vermek (False Positive), bitkiyi tamamen kurutmaktan (False Negative) tarımsal açıdan çok daha kabul edilebilir bir risktir.



Şekil 2: Random Forest Sınıflandırıcısı - Karmaşıklık Matrisi

6.3 Bias-Variance (Yanlılık ve Varyans) Yorumu

Elde edilen sonuçlara göre J48 modeli, çapraz doğrulamada en yüksek genel başarımlı oranını (0.9026) göstererek dengeli bir yapı kurmuştur. Bu durum, sensör veri setinin keskin çevresel kurallarla ayrılabilen bir yapısı olduğunu kanıtlar. Random Forest'ın test setinde 0.99 gibi olağanüstü bir sonuç vermesine rağmen 10-fold CV'de doğruluk oranının 0.84'e düşmesi, modelin eğitim verisine fazla uyum sağladığına (overfitting / yüksek varyans) işaret etmektedir. Öte yandan IBk modeli %68 başarıda kalarak yüksek yanlılık (High Bias / Underfitting) sergilemiş, tarımsal tahminlerde yalnızca geçmiş benzer durumlara bakmanın yeterli olmadığını göstermiştir.

7 Dağıtım (Deployment) ve Gelecek Çalışmalar

Veri madenciliği sürecinin son adımı olan Dağıtım (Deployment) evresi, bu otonom makine öğrenmesi modelinin fiziksel dünyayla nasıl etkileşime gireceğini tanımlar. Geliştirilen sistem mimarisi dört ana katmandan oluşmaktadır [cite: 458-462]: Sensör Katmanı, Kontrol Katmanı, Bulut Veri Katmanı ve Kullanıcı Arayüzü Katmanı.

Gelecek çalışmalarda, eğitilen J48 karar ağacı modeli Python tabanlı bir API (örneğin FastAPI) olarak sunucuya yüklenecektir. Ortamdan veri toplamak amacıyla kapasitif toprak nem sensörü (v1.2) [cite: 494] ve merkezi denetleyici olarak Wi-Fi modüllü ESP32 mikrodenetleyicisi kullanılacaktır[cite: 493].

ESP32, toprak nemi ve hava durumu verilerini saniyeler içinde Wi-Fi üzerinden MQTT protokolü [cite: 500] aracılığıyla bulut veri tabanına (Firebase) iletecektir. Model, bu verileri anlık olarak değerlendirip "Sınıf 2" (Yoğun Sula) sonucuna varırsa, ESP32'ye bir kontrol sinyali gönderecek ve bir röle modülü üzerinden 5V DC su pompasını [cite: 495] çalıştıracaktır. Ayrıca, Flutter kullanılarak geliştirilen [cite: 531] Android ve iOS destekli mobil arayüz üzerinden kullanıcılar, yapay zekanın otonom sulama kararlarını canlı olarak izleyebilecektir[cite: 532].

Kaynaklar

1. Witten, I. H., Frank, E., Hall, M. A., Pal, C. J. (2017). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann.
2. Han, J., Kamber, M., Pei, J. (2022). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
3. Taştan, M. (2019). *IoT Tabanlı Akıllı Sulama Sistemleri ve Uzaktan İzleme*.
4. Yenikaya, S., vd. (2022). *Çoklu Sensör Entegrasyonu ile Hassas Tarım Uygulamaları*.
5. Alpay, T. (2021). "Düşük Maliyetli DTMF tabanlı akıllı sulama sistemi," *Computer Science*, no. Special, pp. 242-249.
6. Öztürk, E., Çelik, Y., & Kırıcı, P. (2021). "Akıllı tarımda sensör uygulaması," *Avrupa Bilim ve Teknoloji Dergisi*, no. 28, pp. 1279-1282.
7. Işık, M. F., Yılmaz, C., & Işık, E. (2017). "Tarımsal arazi sulama sistemlerinde mobil uygulamalar: örnek bir çalışma," *Politeknik Dergisi*, vol. 20, no. 3, pp. 725-731.
8. Kaggle. "Smart Agriculture Dataset". Erişim Tarihi: Haziran 2026.

Ek A: Kod ve Veri Dizini

Projenin kaynak kodlarına, kullanılan veri setine ve canlı geliştirme ortamına aşağıdaki GitHub deposu üzerinden erişilebilir:

<https://github.com/SerraTengis/BLM308-Veri-Madenciligi-akillisulamaproje>

Proje dosyaları GitHub deposunda yönergeye uygun olarak aşağıdaki düzende teslim edilmiştir:

```
proje/  
|-- rapor.pdf  
|-- README.md  
|-- kod/  
|   |-- akilli_sulama_modeli.ipynb  
|-- veri/  
    |-- cropdata_updated.csv
```

Ek B: Yapay Zeka Kullanımı Beyanı

Bu projede Python ortamında kodların yapılandırılması (scikit-learn kütüphanesi fonksiyonlarının ve cross-validation süreçlerinin yazımı) ile raporun LaTeX diline aktararak formatlanması aşamalarında yapay zeka araçlarından (Google Gemini) rehberlik ve şablon yardımı alınmıştır. Verinin yorumlanması, donanım entegrasyonuna (ESP32/Flutter) dair dağıtım senaryoları ve algoritmik tercihler tamamen özgün bir şekilde araştırmacı tarafından kurgulanmıştır.

Ek C: Proje Kapsamında Hedeflenen Bonuslar

Proje yönergesinde belirtilen ek kapsamlar ve inisiyatif gerektiren iyileştirmeler doğrultusunda, bu çalışmada aşağıdaki bonus maddeleri hedeflenmiş ve rapora entegre edilmiştir:

- **LaTeX Kullanımı:** Rapor, standart kelime işlemciler (MS Word vb.) yerine akademik standartlara uygun olarak LaTeX (Overleaf) ortamında dizilmiş ve derlenmiştir.

- **GitHub ve Açık Kaynak Paylaşımı:** Projeye ait Colab kod dosyası (.ipynb), kullanılan veri seti (.csv) ve proje detaylarını açıklayan yapılandırılmış bir README.md dosyası GitHub reposu üzerinden açık kaynak olarak sunulmuştur.
- **Detaylı Hata Analizi (Error Analysis):** Bölüm 5.2’de karmaşıklık matrisi üzerinden yalnızca sayısal doğruluk (accuracy) verilmemiş; modelin tarımsal iş değeri perspektifinden neden hata yaptığı (False Positive ve False Negative maliyetleri) detaylıca yorumlanmıştır.
- **Açık Uçlu İnisiyatif (IoT Dağıtım Vizyonu):** Makine öğrenmesi modeli teorik boyutta bırakılmamış, Bölüm 6’da ESP32, Firebase ve Flutter (mobil arayüz) mimarisi kullanılarak fiziksel bir akıllı sulama donanımına nasıl entegre edileceği (Deployment) kurgulanmıştır.
- **Agile (Çevik) Süreç Yönetimi:** Bireysel bir çalışma olmasına rağmen proje bir mühendislik ürünü olarak ele alınmış, süreç Scrum mantığıyla "Sprint"lere bölünerek Bölüm 1’de İş Kırılım Tablosu (WBS) ile dokümanite edilmiştir.